Asia Euro University

Master of Science in Information Technology Engineering

កម្មវិធីសិក្សាបរិញ្ញាបត្រជាន់ខ្ពស់ | កម្រិត OBE C5 - EVALUATE

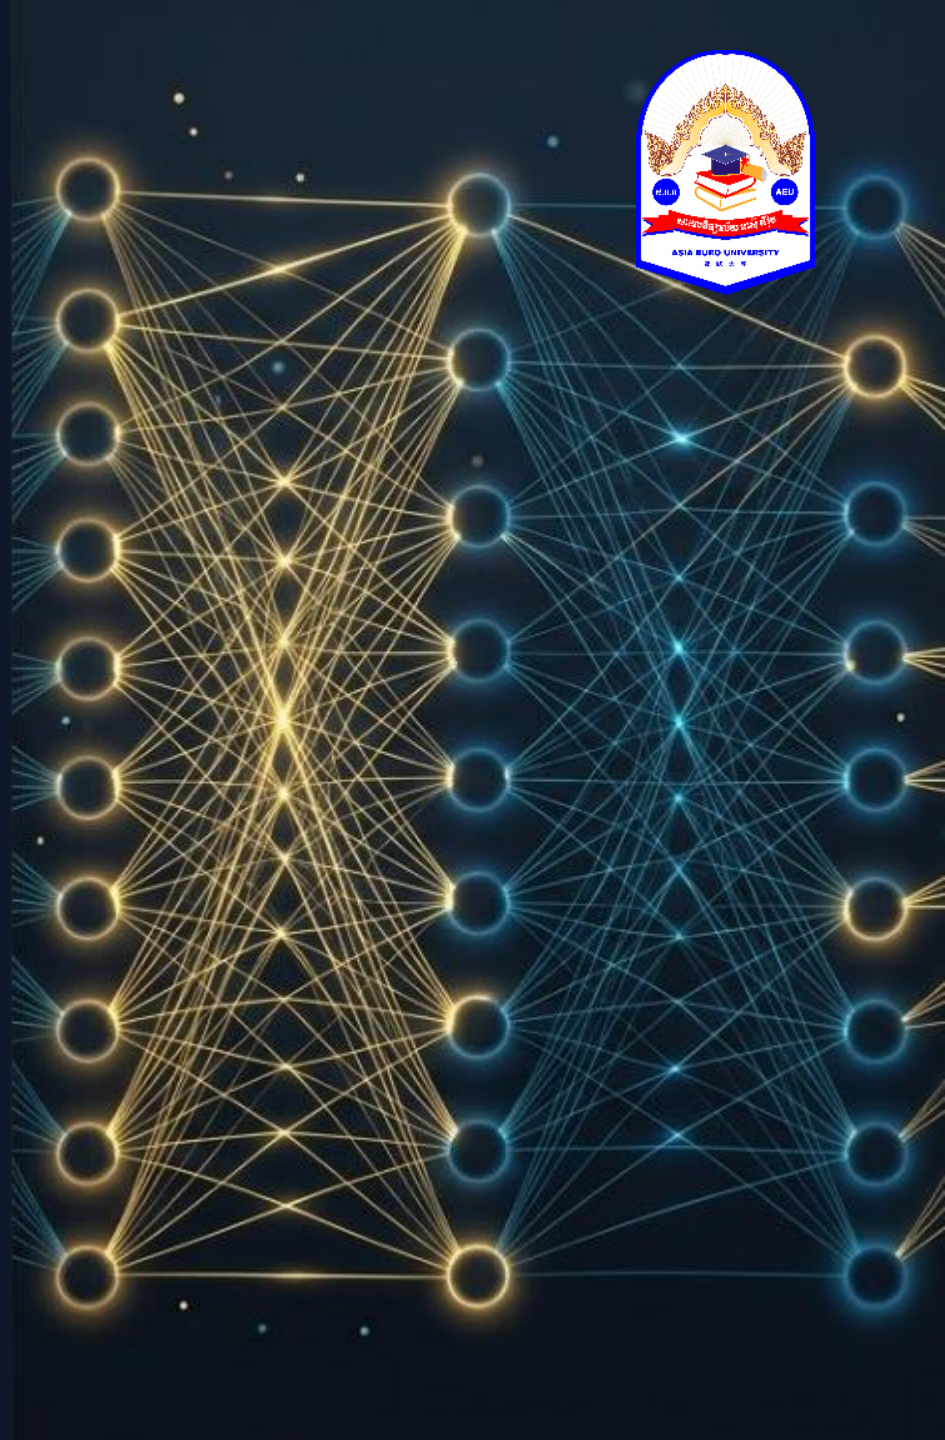
Attention Mechanism & Transformer Architecture

ការវាយតម្លៃទ្រឹស្តី ការគណនាដោយដៃ និងការអនុវត្តជាក់ស្តែងលើភាសាខ្មែរ

Deep Learning / NLP

១៥០–១៨០ នាទី

កម្រិត អនុបណ្ឌិត



ព័ត៌មានទូទៅនៃមេរៀន

បរិបទមេរៀន ឧបករណ៍ និងចំណេះដឹងជាមូលដ្ឋាន

ចំណេះដឹងមុន (Prerequisites)

- Linear Algebra (Matrix Operations)
- Probability & Softmax Function
- Python, NumPy, PyTorch មូលដ្ឋាន
- Neural Networks & NLP Fundamentals

ឧបករណ៍ប្រើប្រាស់ (Tools)

- Python 3.10+, NumPy, PyTorch
- HuggingFace Transformers
- BertViz Visualization Library
- Jupyter Notebook / Google Colab

វិធីសាស្ត្របង្រៀន (Methods)

- Lecture + Manual Computation
- Python Lab (Scratch Code)
- BERT Attention Weight Extraction
- BertViz + Critical Evaluation (C5)

ស្តង់ដារ OUTCOME-BASED EDUCATION (OBE)

លទ្ធផលសិក្សារំពឹងទុក (Course Learning Outcomes - CLO2)

CLO2 (C5 – Evaluate): និស្សិតអាចវាយតម្លៃដំណើរការ Attention Mechanism និងស្ថាបត្យកម្ម Transformer ដោយផ្អែកលើការគណនា ការអនុវត្ត កស្តុតាងពី Attention Weights និងការបកស្រាយវិទ្យាសាស្ត្រ។

LO1

C2 – Understand

ពន្យល់ Self-Attention, Q/K/V, Multi-Head & Positional Encoding។

LO2

C3 – Apply

គណនា Scaled Dot-Product ដោយដៃ និងអនុវត្តជា Python Code។

LO3

C4 – Analyze

វិភាគ Attention Weights ពី Transformer/BERT លើប្រយោគខ្មែរ។

LO4

C5 – Evaluate

វាយតម្លៃ Attention Patterns ដោយ BertViz ជាមួយកស្តុតាងវិទ្យាសាស្ត្រ។

ទ្រឹស្តីមូលដ្ឋាន

ហេតុអ្វីត្រូវផ្លាស់ប្តូរពី RNN/LSTM មក Attention Mechanism?

⚠ RNN / LSTM បុរាណ

Information Bottleneck: បង្ហួមទិន្នន័យទាំងអស់ចូល Context Vector តែមួយ។

Vanishing Gradient: បាត់បង់ព័ត៌មានសម្រាប់ប្រយោគវែងៗ (Long Sequences)។

Sequential Computation: គណនាមួយពាក្យម្តងៗ មិនអាច Parallelize បានឡើយ។

✓ Attention Mechanism

Dynamic Context: ភ្ជាប់ Decoder ទៅគ្រប់ Hidden States របស់ Encoder។

Weighted Focus: ផ្តល់ទម្ងន់សំខាន់លើពាក្យពាក់ព័ន្ធដោយផ្ទាល់។

Parallel Processing: គណនាទិន្នន័យប្រយោគទាំងមូលក្នុងពេលតែមួយលើ GPU។

សមាសភាគគ្រឹះ

សញ្ញាណ Query (Q), Key (K), និង Value (V)

$$Q = X W^T_Q , \quad K = X W^T_K , \quad V = X W^T_V$$

Query (Q)

សំណួរ ឬ Token បច្ចុប្បន្នកំពុងស្វែងរកព័ត៌មានពី Token ផ្សេងទៀត។

Key (K)

ស្លាកសម្គាល់ព័ត៌មាននៃ Token នីមួយៗ សម្រាប់ផ្គូផ្គងជាមួយ Query។

Value (V)

អត្ថន័យ និងព័ត៌មានពិតប្រាកដនៃ Token ដែលត្រូវទាញយកមកប្រើ។

រូបមន្ត និង ដំណើរការ

Scaled Dot-Product Attention Pipeline

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{Q K^T}{\sqrt{d_k}}\right) V$$

ជំហាន ១
Similarity

$Q K^T$ (Dot Product)

→

ជំហាន ២
Scale

ចែកនឹង $\sqrt{d_k}$ (Variance Control)

→

ជំហាន ៣
Softmax

ប្តែងជា Attention Weights

→

ជំហាន ៤
Weighted Sum

គុណ Weights ជាមួយ V

ការវិភាគស៊ីជម្រៅ (CRITICAL ANALYSIS)

តួនាទីរបស់ Scaling Factor $\sqrt{d_k}$ ក្នុងការការពារ Vanishing Gradient

បើគ្មាន Scaling Factor (d_k ធំ)

- តម្លៃ Dot Product ($Q K^T$) នឹងកើនឡើង Variance យ៉ាងខ្លាំងតាមទំហំ d_k។
- ធ្វើឱ្យ Softmax ធ្លាក់ចូលក្នុងតំបន់ Saturation (Very extremely extremely small or large values)។

==> បង្កើត Vanishing Gradient ធ្វើឱ្យ Model មិនអាច រៀន (Learn) បានឡើយ។

ដំណោះស្រាយដោយការចែក $\sqrt{d_k}$

- ប្រសិនបើ Q និង K មាន Mean=0 និង Variance=1 នោះ Dot Product មាន Variance = d_k។
- ការចែកនឹង $\sqrt{d_k}$ ជួយ Normalizes Variance ឱ្យត្រឡប់មកស្មើ 1 វិញ។

==> រក្សា Gradient ស្ថិតក្នុងកម្រិតប្រកបដោយស្ថេរភាព (Stable Backpropagation)។

ការអភិវឌ្ឍសមត្ថភាព

Multi-Head Attention & Positional Encoding

Multi-Head Attention

អនុញ្ញាតឱ្យ Model រៀនពីទំនាក់ទំនងផ្សេងៗគ្នាក្នុង Subspaces ច្រើនក្នុងពេលដំណាលគ្នា។

$$\text{MultiHead} = \text{Concat}(\text{head}_1,\ldots,\text{head}_h)\, W^O$$

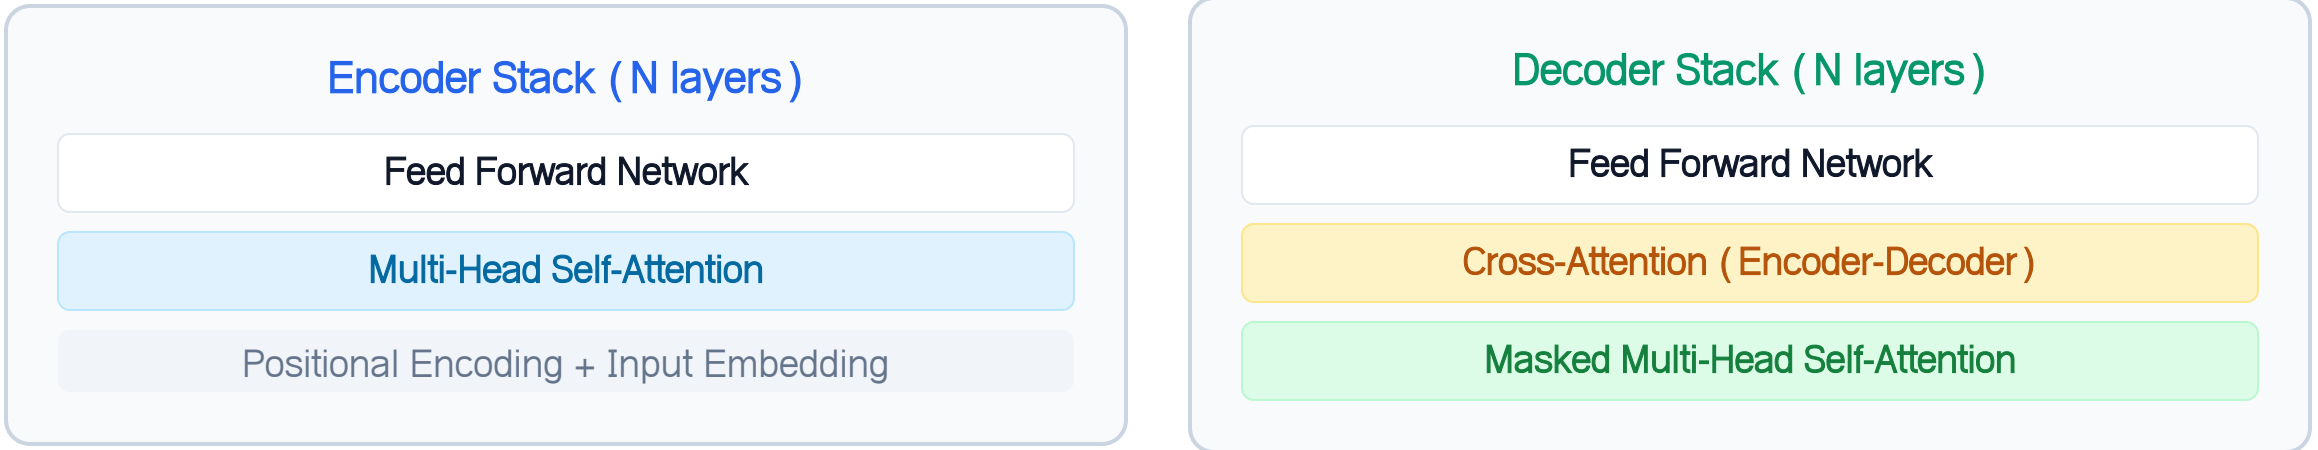
Positional Encoding

បន្ថែមព័ត៌មានទីតាំងពាក្យតាមអនុគមន៍ Sine/Cosine ដោយសារ Transformer គ្មាន Recurrence។

ឧទាហរណ៍៖ «ស្តេចទៅបរបាញ់សត្វ» vs «សត្វទៅបរបាញ់ស្តេច»

ស្ថាបត្យកម្មទូទៅ

Transformer Encoder-Decoder Architecture



ការអនុវត្តគណនាដោយដៃ

លំហាត់គណនា Scaled Dot-Product (ជំហាន ១ & ២)

ទិន្នន័យដើម (Inputs & d_k)

Q = K = [[1,0],[0,1],[1,1],[0,0]]

V = [[1,2],[3,4],[5,6],[7,8]]

$d_k = 2 \Rightarrow \sqrt{d_k} \approx 1.414$

១. គណនា Dot-Product Matrix ($Q K^T$)

Row	Col 1	Col 2	Col 3	Col 4
R1	1	0	1	0
R2	0	1	1	0
R3	1	1	2	0
R4	0	0	0	0

២. Scaled Scores Matrix ($Q K^T / \sqrt{2}$)

R1: [0.707, 0.000, 0.707, 0.000]

R3: [0.707, 0.707, 1.414, 0.000]

ការអនុវត្តគណនាដោយដៃ

លំហាត់គណនា Scaled Dot-Product (ជំហាន ៣ & ៤)

៣. Softmax Attention Weights

Row	W1	W2	W3	W4
R1	0.335	0.165	0.335	0.165
R2	0.165	0.335	0.335	0.165
R3	0.221	0.221	0.449	0.109
R4	0.250	0.250	0.250	0.250

៤. Output = Attention Weights × V

Row	Dim 1	Dim 2
R1	3.660	4.660
R2	4.000	5.000
R3	3.891	4.891
R4	4.000	5.000

LAB IMPLEMENTATION

Python Code: Scaled Dot-Product & Causal Masking

import numpy as np def softmax(x, axis=-1): x_max = np.max(x, axis=axis, keepdims=True) return np.exp(x - x_max) / np.sum(np.exp(x - x_max), axis=axis, keepdims=True) def scaled_dot_product_attention(Q, K, V, mask=None): d_k = Q.shape[-1] scores = np.matmul(Q, K.T) / np.sqrt(d_k) if mask is not None: scores = np.where(mask == 0, -1e9, scores) attn_weights = softmax(scores, axis=-1) output = np.matmul(attn_weights, V) return output, attn_weights # Causal Mask for Decoder causal_mask = np.tril(np.ones((4, 4), dtype=bool)) output, attn = scaled_dot_product_attention(Q, K, V, mask=causal_mask)

```
import numpy as np def softmax(x, axis=-1): x_max = np.max(x, axis=axis, keepdims=True) return np.exp(x - x_max) / np.sum(np.exp(x - x_max), axis=axis, keepdims=True) def scaled_dot_product_attention(Q, K, V, mask=None): d_k = Q.shape[-1] scores = np.matmul(Q, K.T) / np.sqrt(d_k) if mask is not None: scores = np.where(mask == 0, -1e9, scores) attn_weights = softmax(scores, axis=-1) output = np.matmul(attn_weights, V) return output, attn_weights # Causal Mask for Decoder causal_mask = np.tril(np.ones((4, 4), dtype=bool)) output, attn = scaled_dot_product_attention(Q, K, V, mask=causal_mask)
```

ការពិសោធន៍លើភាសាខ្មែរ

HuggingFace BERT / XLM-R Attention Weight Extraction



ប្រយោគពិសោធន៍

«ស្តេចទៅបរបាញ់សត្វ»

Model: xlm-roberta-base

ចំណុចសំខាន់នៃការ Tokenization

Subword Segmentation: ពាក្យខ្មែរត្រូវបានបំបែកជា Subword Tokens។

Multilingual Model: XLM-R គាំទ្រភាសាខ្មែរបានល្អជាង BERT Uncased។

Open Challenge: Khmer Tokenization នៅតែជាប្រធានបទស្រាវជ្រាវចំហ។

VISUALIZATION & ANALYSIS

ការវិភាគ Attention Patterns ដោយ BertViz

Head View Analysis

ប្រៀបធៀប Attention នៃ Heads ផ្សេងៗគ្នា លើ Subject–Verb និង Adj–Noun។

Layer Depth Impact

Layers ជ្រៅចាប់យក Semantic Meaning ជាង Layers ដំបូងដែលចាប់យក Positional Links។

Interpretability Limit

Attention Weights បង្ហាញ Correlation តែមិនមែនជា Full Explanation នៃ Model ទេ។

ផែនការសកម្មភាព (TIMELINE)

កាលវិភាគសកម្មភាពក្នុងថ្នាក់ (១៥០é១៨០ នាទី)

១. ទ្រឹស្តី Attention & Transformer Architecture	បង្រៀនផ្ទាល់ និងពិភាក្សាសញ្ញាណគ្រឹះ	៤៥ នាទី | LO1
២. លំហាត់គណនាដោយដៃ (Manual Scaled Dot-Product)	គណនាតាមក្រុម និងផ្ទៀងផ្ទាត់លទ្ធផល	២០ នាទី | LO2
៣. Lab 1: Python Implementation from Scratch	សរសេរកូដ Python / NumPy / PyTorch	៣០ នាទី | LO2
៤. Lab 2: HuggingFace & BertViz Attention Extraction	ពិសោធន៍លើប្រយោគខ្មែរ និងបង្ហាញ Visualization	៤០ នាទី | LO3, LO4
៥. ពិភាក្សា និងសន្និដ្ឋានកម្រិត C5	វាយតម្លៃកស្តាង និងឆ្លើយសំណួរគន្លឹះ	១៥ នាទី | LO4

ការវាយតម្លៃផលសិក្សា

ទម្ងន់ពិន្ទុ និង ស្តង់ដារវាយតម្លៃ (OBE Rubric)

ទម្ងន់ពិន្ទុ Assessment

សមាសភាគ	ទម្ងន់
សំណួរទ្រឹស្តី Attention	១០%
Manual Scaled Dot-Product	២០%
Multi-Head & Positional Analysis	១៥%
Python/BERT Implementation	២០%
BertViz Visualization	១០%
Critical Evaluation & Interpretation	**២៥%**

Rubric កម្រិត C5 (Evaluate)

- **គណនាដោយដៃ (4/4):** ត្រឹមត្រូវ ១០០% បង្ហាញគ្រប់ជំហានច្បាស់លាស់។
- **កូដ Python (4/4):** ដំណើរការឥតខ្ចោះ Clean Code មាន Comment គ្រប់គ្រាន់។
- **វិភាគ Attention (4/4):** វិភាគជ្រៅ ភ្ជាប់ទ្រឹស្តីជាមួយទិន្នន័យជាក់ស្តែង។
- **Critical Evaluation (4/4):** វាយតម្លៃប្រកបដោយហេតុផល និងភស្តុតាងវិទ្យាសាស្ត្រ។

CRITICAL THINKING (LEVEL C5)

សំណួរពិភាក្សា និងការវាយតម្លៃស៊ីជម្រៅ



១. ហេតុអ្វីត្រូវប្រើ Scaling Factor $\sqrt{d_k}$? តើវាការពារ Vanishing Gradient យ៉ាងដូចម្តេច ?

២. បើគ្មាន Positional Encoding តើ Transformer នឹងប្រឈមមុខនឹងបញ្ហាអ្វីខ្លះ ?

៣. តើ Attention Weights អាចយកមកធ្វើជាកស្តុតាងនៃការរៀបចំវាក្យសម្ព័ន្ធខ្មែរបានដែរឬទេ ?

៤. តើ Attention Weight តែមួយមុខគ្រប់គ្រាន់ក្នុងការបកស្រាយហេតុផលរបស់ Model ទាំងស្រុងដែរឬទេ ?

កិច្ចការផ្ទះ & LEARNING PATHWAY

កិច្ចការផ្ទះ និង មាតិសិក្សា (Assignment & Pathway)

កិច្ចការផ្ទះ (Assignment)

ប្រធានបទ: ការវិភាគ Attention Mechanism ក្នុង BERT សម្រាប់ភាសាខ្មែរ

លទ្ធផលត្រូវដាក់ស្នើ:

- Jupyter Notebook (Code + Outputs)
- របាយការណ៍ PDF វិភាគ និងវាយតម្លៃ (C5)
- បទបង្ហាញ ១០ នាទី ក្នុងថ្នាក់

Learning Pathway (OBE)

1. Understand (C2) - ទ្រឹស្តី Self-Attention & Q/K/V
2. Calculate & Apply (C3) - គណនា Scaled Dot-Product
3. Analyze (C4) - XLM-R / BERT Attention Extraction
4. Evaluate (C5) - Critical Analysis & Scientific Proof

ចំណុចសំខាន់សម្រាប់គ្រូបង្រៀន

ការណែនាំគរុកោសល្យសម្រាប់សាស្ត្រាចារ្យ

1. Model Architecture

BERT គឺ Encoder-only មិនមែន Encoder-Decoder ពេញលេញទេ។ បញ្ជាក់ឱ្យនិស្សិតយល់ច្បាស់ពីភាពខុសគ្នានេះ។

2. Interpretability

Attention Weights បង្ហាញពី Correlation ប៉ុន្តែមិនមែនជា Full Explanation តែមួយគត់របស់ Model ឡើយ។

3. Khmer Tokenization

Khmer Subword Segmentation នៅតែជាប្រធានបទស្រាវជ្រាវចំហ (Open Challenge) សម្រាប់និស្សិតធ្វើប្រធានបទបង្ហាញ។

សន្និដ្ឋាន & សំណួរ-ចម្លើយ

សូមអរគុណសម្រាប់ការយកចិត្តទុកដាក់!

Attention Mechanism & Transformer – គ្រឹះដ៏សំខាន់នៃ AI ទំនើប និង Large Language Models (LLMs)